

Ortogonalidad, Ortonormalidad, Bases, Proyección y Factorización QR

Recordatorio: Producto Interno Canónico

- En $\mathbb{R}^n$: dados dos vectores $x, y \in \mathbb{R}^n$,

$$\langle x, y \rangle = x^T y = \sum_{i=1}^n x_i y_i$$

- En $\mathbb{C}^n$: dados dos vectores $x, y \in \mathbb{C}^n$,

$$\langle x, y \rangle = x^* y = \sum_{i=1}^n \overline{x_i} y_i$$

donde $x^* = \overline{x}^T$ denota el vector fila transpuesto conjugado.

1. Ortogonalidad o Perpendicularidad


Definición: Dados dos vectores no nulos $u, v \in \mathbb{K}^n$, decimos que son *ortogonales* o *perpendiculares* ($u \perp v$) si y solo si su producto interno es nulo:

$$\langle u, v \rangle = u^* v = 0$$

En el caso real $\mathbb{R}^n$, la desigualdad de Cauchy-Schwarz permite definir el ángulo θ entre u y v mediante:

$$\cos(\theta) = \frac{\langle u, v \rangle}{\|u\|_2 \|v\|_2}$$

Por lo tanto, $\theta = \frac{\pi}{2}$ (ángulo recto de 90°) ocurre si y solo si $\langle u, v \rangle = 0$.



2. Definición de Conjunto Ortogonal

Una colección de vectores no nulos $\{v_1, v_2, \dots, v_k\} \subset \mathbb{K}^n$ se dice un *conjunto ortogonal* si todos sus pares son perpendiculares entre sí:

$$v_i^* v_j = 0 \quad \text{para todo } i \neq j$$

Propiedad fundamental: Todo conjunto ortogonal de vectores no nulos es *linealmente independiente* (LI).

3. Definición de Conjunto Ortonormal

Una colección de vectores $\{q_1, q_2, \dots, q_k\} \subset \mathbb{K}^n$ es un *conjunto ortonormal* si es ortogonal y además cada uno de sus vectores tiene norma euclídea unitaria ($\|q_i\|_2 = 1$). De forma compacta:

$$q_i^* q_j = \delta_{ij} = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases}$$

donde δ_{ij} es la delta de Kronecker.

4. Paso de un Conjunto Ortogonal a uno Ortonormal: Normalización

Si se dispone de un conjunto $\{v_1, \dots, v_k\}$ de vectores no nulos que *ya es ortogonal* ($v_i^* v_j = 0$ para $i \neq j$), para convertirlo en un conjunto ortonormal basta con **normalizar** cada uno de sus elementos:

$$q_i = \frac{v_i}{\|v_i\|_2} \quad \text{para cada } i = 1, \dots, k$$

El conjunto resultante $\{q_1, \dots, q_k\}$ es automáticamente un conjunto ortonormal:

1. Cada vector tiene norma 1:

$$\|q_i\|_2 = \left\| \frac{v_i}{\|v_i\|_2} \right\|_2 = \frac{\|v_i\|_2}{\|v_i\|_2} = 1$$

2. Se preserva la ortogonalidad para $i \neq j$:

$$q_i^* q_j = \left(\frac{v_i}{\|v_i\|_2} \right)^* \left(\frac{v_j}{\|v_j\|_2} \right) = \frac{v_i^* v_j}{\|v_i\|_2 \|v_j\|_2} = \frac{0}{\|v_i\|_2 \|v_j\|_2} = 0$$

En consecuencia, $q_i^* q_j = \delta_{ij}$. Si el conjunto original $\{v_1, \dots, v_n\}$ era una base ortogonal de $\mathbb{K}^n$, entonces $\{q_1, \dots, q_n\}$ es una **base ortonormal (BON)**.

Observación: Si el conjunto de partida es únicamente linealmente independiente (LI) pero no es ortogonal, dividir cada vector por su norma solo los hace unitarios pero *no ortogonales*. En ese caso general, es necesario aplicar previamente el proceso de ortogonalización de Gram-Schmidt.

5. Definición de Base Ortonormal BON

Un conjunto $B = \{q_1, q_2, \dots, q_n\} \subset \mathbb{K}^n$ es una *base ortonormal (BON)* si es una base de $\mathbb{K}^n$ y sus elementos forman un conjunto ortonormal.

6. Coordenadas y Matrices de Cambio de Base en una BON

Cálculo directo de coordenadas: Dada una base ortonormal $B = \{q_1, \dots, q_n\}$ de $\mathbb{K}^n$, cualquier vector $w \in \mathbb{K}^n$ se expresa de forma única como:

$$w = \sum_{i=1}^n \alpha_i q_i$$

Al multiplicar a izquierda por q_j^* , la ortonormalidad anula todos los términos con $i \neq j$:

$$q_j^* w = \sum_{i=1}^n \alpha_i (q_j^* q_i) = \alpha_j$$

Por lo tanto, las coordenadas en una base ortonormal se obtienen mediante productos internos directos, sin resolver sistemas de ecuaciones:

$$(w)_B = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{pmatrix} = \begin{pmatrix} q_1^* w \\ \vdots \\ q_n^* w \end{pmatrix} = Q^* w$$

donde $Q = (q_1 \ \cdots \ q_n)$. Además, se cumple la *Identidad de Parseval*:

$$\|w\|_2^2 = \sum_{i=1}^n |\alpha_i|^2$$

Matrices de cambio de base e inversa (Inciso b):

Dada una base $B = \{v_1, v_2, \dots, v_n\}$ de $\mathbb{K}^n$ y la base canónica $E = \{e_1, \dots, e_n\}$:

- **Matriz de cambio de B a canónica (C_{BE}):** Sus columnas son directamente los vectores de la base B expresados en la canónica:

$$C_{BE} = (v_1 \ v_2 \ \cdots \ v_n)$$

Esta matriz mapea coordenadas según $(v)_E = C_{BE}(v)_B$.

- **Matriz de cambio de canónica a B (C_{EB}):** Efectúa el camino inverso:

$$(v)_B = C_{EB}(v)_E \implies C_{EB} \cdot C_{BE} = I_n \iff C_{EB} = (C_{BE})^{-1}$$

- En el caso general, hallar C_{EB} requiere invertir la matriz mediante Gauss-Jordan.
- Si la base B es **ortogonal**, su inversa se halla sin recurrir a Gauss-Jordan disponiendo los vectores como filas conjugadas divididos por su norma al cuadrado:

$$C_{EB} = \begin{pmatrix} \frac{v_1^*}{\|v_1\|_2^2} \\ \vdots \\ \frac{v_n^*}{\|v_n\|_2^2} \end{pmatrix}$$

- Si la base B es **ortonormal**, como $\|v_i\|_2^2 = 1$ para todo i , la matriz C_{EB} colapsa a:

$$C_{EB} = \begin{pmatrix} v_1^* \\ \vdots \\ v_n^* \end{pmatrix} = (v_1 \ \cdots \ v_n)^* = C_{BE}^*$$

- Demostrando que en toda base ortonormal, la inversa de la matriz de cambio de base es exactamente su adjunta: $C_{EB} = C_{BE}^*$.


7. Proyección Ortogonal

Proyección sobre una recta: La proyección ortogonal de un vector w sobre la recta generada por $v \neq 0$ es el vector βv tal que $(w - \beta v) \perp v$:

$$P_v(w) = \frac{v^* w}{\|v\|_2^2} v$$

Si el vector está normalizado ($\|v\|_2 = 1$), la fórmula colapsa a la acción de una matriz de rango 1:

$$P_v(w) = (v^* w) v = (v v^*) w$$



Proyección sobre un subespacio S : Si $\{q_1, \dots, q_k\}$ es una BON del subespacio S , la proyección de w sobre S es la suma de sus proyecciones unidimensionales:

$$P_S(w) = \sum_{i=1}^k P_{q_i}(w) = \sum_{i=1}^k (q_i^* w) q_i = Q Q^* w$$

donde $Q = (q_1 \ \dots \ q_k) \in \mathbb{K}^{n \times k}$. La matriz $P = Q Q^*$ es el *proyector ortogonal* sobre S y satisface:

$$P^2 = P \quad (\text{idempotente}) \quad \text{y} \quad P^* = P \quad (\text{autoadjunto / simétrico})$$

Factorización QR

Dada una matriz $A \in \mathbb{R}^{m \times n}$ con $m \geq n$ y columnas linealmente independientes, la factorización QR descompone a la matriz como:

$$A = QR$$

donde:

- $Q \in \mathbb{R}^{m \times m}$ (o reducida en $\mathbb{R}^{m \times n}$) posee columnas ortonormales ($Q^T Q = I$).
- $R \in \mathbb{R}^{m \times n}$ (o reducida cuadrada en $\mathbb{R}^{n \times n}$) es triangular superior ($r_{ij} = 0$ para todo $i > j$).

Método 1: Ortogonalización de Gram-Schmidt Modificado (MGS)

Procedimiento Práctico a Mano (en Papel) Para una matriz $A = (a_1 \ a_2 \ \dots \ a_n) \in \mathbb{R}^{n \times n}$:

1. Primera columna ($j = 1$):

- Calcular la longitud: $r_{11} = \|a_1\|_2 = \sqrt{\sum_i a_{i1}^2}$.
- Normalizar: $q_1 = \frac{a_1}{r_{11}}$.

2. Sigüientes columnas ($j = 2, \dots, n$):

- Inicializar el acumulador: $\tilde{q}_j = a_j$.
- Para cada vector ortonormal previo q_k ($k = 1, \dots, j-1$):

$$r_{kj} = q_k^T \tilde{q}_j \quad (\text{coeficiente de proyección})$$

$$\tilde{q}_j \leftarrow \tilde{q}_j - r_{kj} q_k \quad (\text{restar la componente paralela})$$

- Medir la norma del residuo ortogonal: $r_{jj} = \|\tilde{q}_j\|_2$.
- Normalizar: $q_j = \frac{\tilde{q}_j}{r_{jj}}$.

3. Ensamblado:

Se colocan los vectores unitarios calculados en las columnas de $Q = (q_1 \ \dots \ q_n)$ y los escalares r_{kj} y r_{jj} en la matriz triangular superior R .

Formulación Algorítmica (Python / Sin uso de @) El algoritmo opera sin recurrir a operadores prohibidos (@, np.matmul) y manteniendo los vectores en 1D para evitar discrepancias de dimensiones en las operaciones de normas:

```
def QR_con_GS(A, tol=1e-12):
    n = A.shape[0]
    Q = np.zeros((n, n), dtype=float)
    R = np.zeros((n, n), dtype=float)

    for j in range(n):
        u_j = A[:, j].copy().astype(float)

        for k in range(j):
            q_k = Q[:, k]
            # r_kj = q_k^T * u_j (escalar)
            r_kj = mult_matrices(traspuesta(q_k.reshape(n, 1)), u_j.reshape(n, 1))[0, 0]
            R[k, j] = r_kj
            # u_j = u_j - r_kj * q_k (ortogonalizacion)
            u_j -= r_kj * q_k

        r_jj = norma(u_j, 2)
        if r_jj > tol:
            R[j, j] = r_jj
            Q[:, j] = u_j / r_jj
        else:
            R[j, j] = 0.0
            Q[:, j] = 0.0

    return Q, R
```

Método 2: Reflexiones de Householder

Procedimiento Práctico a Mano (en Papel) Householder anula todos los elementos subdiagonales de cada columna de una sola vez aplicando matrices simétricas y ortogonales $H = I - 2uu^T$ con $\|u\|_2 = 1$.

1. Se parte de $R = A$ y $Q = I_m$.

2. Para cada paso $k = 1, \dots, n$:

- Extraer el vector de la columna actual desde la diagonal hacia abajo:

$$x = R[k : m, k]$$

- Calcular su norma euclídea: $\|x\|_2 = \sqrt{x_1^2 + \dots + x_p^2}$.
- Elegir el escalar α con signo opuesto a la primera componente x_1 (para evitar cancelación numérica por resta de valores similares):

$$\alpha = -\text{sign}(x_1)\|x\|_2 \quad (\text{si } x_1 = 0 \text{ se toma } \text{sign} = 1)$$

- Construir el vector reflector u :

$$u = x - \alpha e_1 = \begin{pmatrix} x_1 - \alpha \\ x_2 \\ \vdots \end{pmatrix}$$

- Normalizar el vector u : $\hat{u} = \frac{u}{\|u\|_2}$.
- Formar el reflector del bloque: $H_k = I - 2\hat{u}\hat{u}^T$.
- Expandir al tamaño global $m \times m$:

$$\tilde{H}_k = \begin{pmatrix} I_{k-1} & 0 \\ 0 & H_k \end{pmatrix}$$

- Actualizar las matrices:

$$R \leftarrow \tilde{H}_k R, \quad Q \leftarrow Q \tilde{H}_k^T$$

(Como $\tilde{H}_k$ es simétrica, $\tilde{H}_k^T = \tilde{H}_k$).

3. Al finalizar los n pasos, la matriz R tiene ceros exactos por debajo de su diagonal principal.

Formulación Algorítmica (Python / Sin uso de @) Implementación que soporta matrices rectangulares $m \times n$ ($m \geq n$):

```
def QR_con_HH(A, tol=1e-12):
    m, n = A.shape
    R = A.copy().astype(float)
    Q = np.eye(m, dtype=float)

    for k in range(n):
        x = R[k:m, k].copy()
        norm_x = norma(x, 2)
        if norm_x < tol:
            continue

        # alpha = -sign(x_1) * ||x||_2
        signo = 1.0 if x[0] >= 0 else -1.0
        alpha = -signo * norm_x

        # Vector reflector u = x - alpha * e_1
        u = x.copy()
        u[0] -= alpha
        norm_u = norma(u, 2)

        if norm_u > tol:
            u = u / norm_u
            dim_bloque = m - k
            u_col = u.reshape(dim_bloque, 1)

            # Reflector local H_k = I - 2 * u * u^T
            H_k = np.eye(dim_bloque) - 2.0 * mult_matrices(u_col, traspuesta(u_col))

            # Reflector expandido H_tilde de m x m
            H_tilde = np.eye(m, dtype=float)
            H_tilde[k:m, k:m] = H_k

            # R <- H_tilde * R y Q <- Q * H_tilde^T
            R = mult_matrices(H_tilde, R)
            Q = mult_matrices(Q, traspuesta(H_tilde))
```

```
R[np.abs(R) < tol] = 0.0
return Q, R
```

9. Matrices Ortogonales

Definición: Una matriz cuadrada $Q \in \mathbb{R}^{n \times n}$ es *ortogonal* (unitaria en $\mathbb{C}^{n \times n}$) si satisface:

$$Q^T Q = Q Q^T = I_n \iff Q^{-1} = Q^T$$

Propiedades Fundamentales:

1. Sus columnas forman una base ortonormal de $\mathbb{R}^n$.
2. Sus filas forman una base ortonormal de $\mathbb{R}^n$.
3. **Isometría (conservación de la norma):** $\|Qx\|_2 = \|x\|_2$ para todo vector $x \in \mathbb{R}^n$.
4. **Conservación de ángulos y producto escalar:** $\langle Qx, Qy \rangle = \langle x, y \rangle$.
5. **Norma matricial subordinada:** $\|Q\|_2 = 1$ y $\|Q^{-1}\|_2 = \|Q^T\|_2 = 1$.
6. **Número de condición óptimo:**

$$\kappa_2(Q) = \|Q\|_2 \cdot \|Q^{-1}\|_2 = 1 \cdot 1 = 1$$

lo que significa que multiplicar por una matriz ortogonal no amplifica errores de redondeo numérico.

7. **Invariancia de normas bajo transformaciones ortogonales:** Para cualquier matriz A ,

$$\|QA\|_2 = \|A\|_2 \quad \text{y} \quad \|QA\|_F = \|A\|_F$$

8. **Determinante:** $\det(Q) = \pm 1$ (si $\det(Q) = 1$ es una rotación pura; si $\det(Q) = -1$ incluye una reflexión).
9. **Espectro:** Todos sus autovalores tienen módulo unitario ($|\lambda_i| = 1$).