

Guía de Estudio: Procesos y Matrices de Markov

Álgebra Lineal Computacional (ALC)

Resumen teórico, herramientas prácticas para ejercicios y conexiones estructurales

Motivación: El Modelo Google PageRank y Caminatas Aleatorias

1. Planteo intuitivo: ¿Cómo ordenar la web por relevancia?

En los inicios de los motores de búsqueda, determinar la importancia relativa de una página web se convirtió en un desafío central. Una primera aproximación intuitiva consiste en contar la cantidad de hipervínculos que apuntan a cada sitio. Sin embargo, no todos los enlaces tienen el mismo peso: recibir una recomendación o enlace desde una página muy influyente (como Wikipedia) otorga más relevancia que recibirla desde un sitio desconocido.

Para resolver esta aparente circularidad ("una página es importante si es referenciada por páginas importantes"), el algoritmo de Google PageRank modela la navegación web mediante un **caminante aleatorio** (*random surfer*):


1. Imaginemos una población fija de internautas navegando por una red.
2. En el instante inicial $k = 0$, cada visitante elige una página departida.
3. En cada paso de tiempo discreto $k \rightarrow k + 1$, si el navegante se encuentra en una página con d enlaces salientes disponibles, elije al azar cualquiera de ellos de manera equiprobable con probabilidad $1/d$.
4. Nos preguntamos: tras navegar mucho tiempo ($k \rightarrow \infty$), ¿cuál es la probabilidad o proporción de visitantes que se encontrará en cada página

2. Diagrama de Estados y Transiciones

Consideremos una subred compuesta por 4 sitios web interconectados: A , B , C y D .

- Desde la página A hay enlaces hacia B o puede quedarse en A (2 enlaces disponibles).
- Desde la página B hay 3 enlaces salientes, hacia A , C o puede quedarse en B (3 enlaces disponibles).
- Desde la página C el internauta puede quedarse en C (autoenlace) o pasar a B (2 enlaces disponibles).
- Desde la página D hay enlaces salientes hacia A y C y puede quedarse en D (autoenlace) (3 enlaces disponibles).

El siguiente diagrama de transiciones ilustra el sistema de estados discretos:



3. Del Grafo a la Matriz de Transición de Markov

Este proceso se puede plantear matricialmente.

Llamamos $v^{(0)}$ al estado inicial del sistema.

$$v^{(0)} = \begin{pmatrix} A^{(0)} \\ B^{(0)} \\ C^{(0)} \\ D^{(0)} \end{pmatrix} = \begin{pmatrix} 1000 \\ 1000 \\ 1000 \\ 1000 \end{pmatrix}$$

Llamamos $v^{(1)}$ al estado del sistema al minuto.

$$v^{(1)} = \begin{pmatrix} A^{(1)} \\ B^{(1)} \\ C^{(1)} \\ D^{(1)} \end{pmatrix} = \begin{pmatrix} 1/2 & 1/4 & 0 & 1/4 \\ 1/2 & 1/2 & 1/2 & 0 \\ 0 & 1/4 & 1/2 & 1/4 \\ 0 & 0 & 0 & 1/2 \end{pmatrix} \begin{pmatrix} A^{(0)} \\ B^{(0)} \\ C^{(0)} \\ D^{(0)} \end{pmatrix}$$

En general

$$v^{(k+1)} = \begin{pmatrix} A^{(k+1)} \\ B^{(k+1)} \\ C^{(k+1)} \\ D^{(k+1)} \end{pmatrix} = \begin{pmatrix} 1/2 & 1/4 & 0 & 1/4 \\ 1/2 & 1/2 & 1/2 & 0 \\ 0 & 1/4 & 1/2 & 1/4 \\ 0 & 0 & 0 & 1/2 \end{pmatrix} \begin{pmatrix} A^{(k)} \\ B^{(k)} \\ C^{(k)} \\ D^{(k)} \end{pmatrix}$$

1. Definición del Proceso y Matrices de Markov

Definición 1 (Matriz de Markov / Estocástica por Columnas). Una matriz cuadrada $M = (m_{ij}) \in \mathbb{R}^{n \times n}$ se dice **matriz de Markov** (o estocástica) si cumple simultáneamente:

1. **No negatividad:** $m_{ij} \geq 0$ para todo $1 \leq i, j \leq n$.
2. **Suma unitaria por columnas:** Para cada columna $j \in \{1, \dots, n\}$,

$$\sum_{i=1}^n m_{ij} = m_{1j} + m_{2j} + \dots + m_{nj} = 1.$$

En notación matricial compacta con $\mathbf{1} = (1, 1, \dots, 1)^T$, la condición de columnas equivale a $\mathbf{1}^T M = \mathbf{1}^T$.

Observación 1. Si A es **matriz de Markov** entonces todas las entradas $a_{ij} \in [0, 1]$.

Definición 2. Un proceso dado iterativamente por $v^{(k+1)} = Av^{(k)}$ con $k \geq 0$ se llama **proceso de Markov**. A cada vector $v^{(k)}$ se lo llama **estado** del sistema en tiempo k . A la matriz A se la llama **matriz de transición**.

2. Autovalor de las Matrices de Markov

Proposición 1. Sea $A \in \mathbb{R}^{n \times n}$ **matriz de Markov**, entonces

1. **Existencia del autovalor 1:** $\lambda = 1$ es siempre autovalor de A .

2. Si λ es **autovalor** de $A \rightarrow \|\lambda\| \leq 1$.

Demostración 1. – 1.

$$A = (C_1(A) | \cdots | C_n(A))$$

$$\rightarrow A^t = \begin{pmatrix} C_1(A) \\ \vdots \\ C_n(A) \end{pmatrix} \text{ los elementos de cada fila suman } 1$$

$$A^t \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \rightarrow 1 \text{ es autovalor de } A^t \text{ con } \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \text{ autovector asociado}$$

$$A^t.v = 1.v$$

Dado que A y A^T comparten el mismo polinomio característico ($\det(A^T - \lambda I) = \det((A - \lambda I)^T) = \det(A - \lambda I)$), tienen exactamente los mismos autovalores, concluyendo que $\lambda = 1$ es autovalor de A .

– 2. **Cota espectral / Radio espectral** $\lambda \leq 1$: Para todo autovalor λ de A , se verifica:

$$|\lambda| \leq 1.$$

Sea $v \neq \mathbf{0}$ autovector tal que $Mv = \lambda v$.

$$v = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \quad A \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} x_1 \\ \vdots \\ x_i \\ \vdots \\ x_n \end{pmatrix}$$

$$\lambda x_i = F_i(A)X = \sum_{j=1}^n a_{ij}x_j$$

Tomando módulo y desigualdad triangular para cada componente i :

$$|\lambda x_i| \leq |\lambda| |x_i| = \left| \sum_{j=1}^n a_{ij}x_j \right| = \sum_{j=1}^n a_{ij} |x_j| \quad (\text{pues } a_{ij} \geq 0, A \text{ es matriz de Markov})$$

$$\rightarrow \sum_{i=1}^n |\lambda| |x_i| \leq \sum_{i=1}^n \sum_{j=1}^n a_{ij} |x_j| = \sum_{j=1}^n \sum_{i=1}^n a_{ij} |x_j| = \sum_{j=1}^n \left(\sum_{i=1}^n a_{ij} \right) |x_j| = \sum_{j=1}^n (1) |x_j|$$

$$\rightarrow \sum_{i=1}^n |\lambda| |x_i| = |\lambda| \sum_{i=1}^n |x_i| \leq \sum_{j=1}^n |x_j|$$

Como $v \neq \mathbf{0}$, $\|v\|_1 > 0$, dividiendo resulta $|\lambda| \leq 1$.

$$\rightarrow |\lambda| \frac{\sum_{i=1}^n |x_i|}{\sum_{i=1}^n |x_i|} = \frac{\sum_{j=1}^n |x_j|}{\sum_{i=1}^n |x_i|}$$

$$\rightarrow |\lambda| \leq \frac{\sum_{j=1}^n |x_j|}{\sum_{i=1}^n |x_i|} \quad (j, i \text{ recorren todo el vector } X)$$

$$\rightarrow |\lambda| \leq 1$$

Proposición 2. Sea A una **matriz de Markov** y λ es autovalor de A , $\lambda \neq 1$.

Si $v = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$ es un autovector asociado a $\lambda \rightarrow x_1 + \cdots + x_n = 0$

Demostración 2. Multiplicando la ecuación $Mv = \lambda v$ a izquierda por $\mathbf{1}^T$:

$$\mathbf{1}^T(Mv) = (\mathbf{1}^T M)v = \mathbf{1}^T v = \lambda(\mathbf{1}^T v) \implies (1 - \lambda)(\mathbf{1}^T v) = 0.$$

Como $\lambda \neq 1$, se deduce inmediatamente que $\mathbf{1}^T v = 0$.

3. Estados de Equilibrio y Convergencia a Largo Plazo

Definición 3 (Estado de Equilibrio / Estacionario). A **matriz de Markov**, v es un **estado de equilibrio** si:

$$Av = v \text{ (} v \text{ es autovector asociado al autovalor 1)}$$

- Con coordenadas NO negativas
- Con coordenadas que suman 1

Observación 2. Si $v = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$ es un autovector asociado a 1

$$\rightarrow \frac{v}{\sum_{i=1}^n x_i} \text{ es autovector del autovalor 1 y sus coordenadas suman 1}$$

Propiedades 1. A matriz de Markov

1. Existe al menos 1 equilibrio
2. **Propiedad clave del autoespacio E_1 :** El subespacio propio $E_1 = \text{Nu}(M - I)$ tiene dimensión al menos 1.
3. No toda **matriz de Markov** es **diagonalizable**

Descomposición Espectral y Límite M^k

Supongamos que M es diagonalizable: $M = CDC^{-1}$, donde $C = (w_1 \mid w_2 \mid \cdots \mid w_n)$ contiene los autovectores y $D = \text{diag}(\lambda_1, \dots, \lambda_n)$ con $1 = \lambda_1 \geq |\lambda_2| \geq \cdots \geq |\lambda_n|$.

Para cualquier estado inicial $\pi^{(0)} \in \mathcal{P}_n$, expresado en la base de autovectores $\pi^{(0)} = a_1 w_1 + \cdots + a_n w_n$:

$$\pi^{(k)} = M^k \pi^{(0)} = a_1 \lambda_1^k w_1 + a_2 \lambda_2^k w_2 + \cdots + a_n \lambda_n^k w_n.$$

- Si $|\lambda_i| < 1$, entonces $\lim_{k \rightarrow \infty} \lambda_i^k = 0$.
- Si $\lambda = 1$ es el **único** autovalor de módulo 1 con multiplicidad 1 (autovalor dominante estricto):

$$\lim_{k \rightarrow \infty} \pi^{(k)} = a_1 w_1 = \pi^* \text{ independientemente del estado inicial } \pi^{(0)}.$$

- En tal caso, la matriz límite $M^\infty = \lim_{k \rightarrow \infty} M^k$ existe y todas sus columnas son idénticas e iguales al vector de equilibrio estacionario:

$$M^\infty = \begin{pmatrix} \pi^* & \pi^* & \cdots & \pi^* \end{pmatrix}.$$

¿Cuándo NO converge el proceso? Si la matriz tiene otros autovalores de módulo 1 (por ejemplo, $\lambda = -1$ o raíces de la unidad $e^{i\theta}$ con matrices periódicas o bloques cíclicos), el término λ_i^k oscilará y el límite $\lim_{k \rightarrow \infty} \pi^{(k)}$ no existirá para ciertos estados iniciales.

4. Conexiones con Otros Temas de ALC

Tema de la Materia	Conexión con Procesos de Markov
Normas Matriciales	$\ M\ _1 = \max_j \sum_i m_{ij} = 1$. Como el radio espectral verifica $\rho(M) \leq \ M\ $ para toda norma inducida, esto prueba analíticamente en una sola línea que $\rho(M) \leq 1$.
Círculos de Gershgorin	Para M^T , cada centro es m_{jj} y el radio es $R_j = \sum_{i \neq j} m_{ij} = 1 - m_{jj}$. Cada disco de Gershgorin es $D(m_{jj}, 1 - m_{jj}) \subset \{z \in \mathbb{C} : z \leq 1\}$ y toca tangencialmente al punto $z = 1$.
Método de la Potencia	La iteración de Markov $\pi^{(k)} = M\pi^{(k-1)}$ es <i>exactamente</i> el método de la potencia aplicado a M para converger al autovector dominante asociado a $\lambda_1 = 1$, con la ventaja de que no se requiere renormalizar por norma euclídea en cada paso porque la norma-1 se preserva automáticamente.
Teorema de Perron-Frobenius	Para matrices regulares (o ergódicas, donde alguna potencia $M^k > 0$ es estrictamente positiva), el autovalor 1 es simple, todo otro autovalor cumple $ \lambda < 1$, y el autovector estacionario π^* tiene todas sus componentes estrictamente positivas ($\pi_i^* > 0$).
Google PageRank	El algoritmo PageRank construye una matriz de Markov $M = dP + \frac{1-d}{n}\mathbf{1}\mathbf{1}^T$ con factor de amortiguación $d \in (0, 1)$, garantizando que la matriz sea estrictamente positiva y tenga un único vector de equilibrio calculable mediante iteraciones.

5. Guía Práctica: Paso a Paso para Resolver Ejercicios

Paso 1: Construir la Matriz de Transición M :

- Identificar los estados $1, 2, \dots, n$.
- Definir cada columna j : ubicar en la posición (i, j) la probabilidad o tasa de pasaje del estado j al estado i .
- *Checklist obligatorio*: verificar que $m_{ij} \geq 0$ y que la suma de cada columna sea exactamente 1 ($\sum_i m_{ij} = 1$).

Paso 2: Hallar los Estados de Equilibrio:

- Plantear el sistema homogéneo $(M - I)\pi = \mathbf{0}$.
- Triangular la matriz $(M - I)$ mediante eliminación gaussiana para encontrar el núcleo $\text{Nu}(M - I)$. (Recuerda que $\det(M - I) = 0$ siempre, por lo que al menos una fila se anulará).
- Parametrizar las soluciones y normalizar el vector dividiendo por la suma de sus componentes: $\pi^* = \frac{v}{\sum_i v_i}$ para que $\pi^* \in \mathcal{P}_n$.

Paso 3: Analizar la Existencia del Límite $\lim_{k \rightarrow \infty} \pi^{(k)}$:

- Calcular las raíces del polinomio característico $\det(M - \lambda I) = 0$.
- Si $\lambda = 1$ tiene multiplicidad 1 y todos los demás autovalores cumplen $|\lambda_i| < 1$, el proceso converge siempre al único π^* para cualquier $\pi^{(0)}$.
- Si existen autovalores complejos con $|\lambda| = 1$ o $\lambda = -1$, el límite dependerá del estado inicial (puede ciclar u oscilar).

Paso 4: Cálculo en k Pasos Finitos o Potencias Altas:

- Si k es pequeño (ej. $k = 2$ o 4): multiplicar recursivamente $\pi^{(1)} = M\pi^{(0)}$, $\pi^{(2)} = M\pi^{(1)}$, etc.
- Si k es general: diagonalizar $M = CDC^{-1}$, calcular $M^k = CD^kC^{-1}$ y evaluar $\pi^{(k)} = M^k\pi^{(0)}$.